





Loading.....



Starting the Presentation



THE PLAYER




Compilo codice dal 1989,
ma ho ancora l'entusiasmo
del primo 'Hello World



www.gfasulo.it / www.linkedin.com/in/gianpiero-fasulo






VANTAGGI VS SVANTAGGI

I principali vantaggi:


- **Gratuità:** modelli eseguiti localmente non richiedono il pagamento di alcun abbonamento.
- **Privacy assoluta dei dati:** Poiché non si collegano a un cloud esterno, consentono di caricare ed elaborare anche le informazioni più sensibili senza doversi preoccupare della condivisione o della perdita di dati.
- **Funzionamento offline:** è possibile utilizzare queste intelligenze artificiali anche in assenza di una connessione a internet



VANTAGGI VS SVANTAGGI

I principali Svantaggi:

- Assenza di aggiornamenti in tempo reale:** Di default, non avendo accesso a internet, questi modelli non dispongono di informazioni aggiornate. Ad esempio, non sono in grado di effettuare ricerche basate sull'attualità o fornire notizie relative al giorno stesso.
- Minori funzionalità di generazione:** Rispetto ai modelli di frontiera disponibili su cloud (come le versioni complete di Gemini o ChatGPT), i modelli locali offrono meno funzionalità. Sebbene alcune varianti siano in grado di analizzare testo, immagini e audio forniti dall'utente, l'intelligenza artificiale locale può generare esclusivamente testo in output, e non è quindi in grado di creare immagini, video o file audio.
- Elevati requisiti hardware (per i modelli più potenti):** I modelli di IA sono sostanzialmente pesanti e richiedono molta memoria e potenza di calcolo. Per far girare i modelli più intelligenti e avanzati (come ad esempio le versioni a 31 miliardi di parametri) è necessario disporre di un computer fisso con hardware di fascia medio-alta. Bisogna comunque notare che esistono versioni più leggere (da 2 o 4 miliardi di parametri) pensate appositamente per funzionare anche su laptop e dispositivi mobili.



WELCOME

// Google Developer Group (GDG) Masterclass

Gemma 4 in Produzione Locale


Dal Blueprint di Google all'architettura di una Web App AI (Double-Pass Inference).

> localhost:8000 avvio in corso...█

DEEP DIVE

L'Alba di **Gemma 4**

Rilasciata ad aprile 2026, Gemma 4 non è un semplice aggiornamento incrementale, ma una **rivoluzione nell'ecosistema Open Models** di Google. Progettata per superare i limiti dei modelli "solo testo", introduce la multimodalità nativa e un'efficienza senza precedenti per l'esecuzione locale.



STRATEGY

Perché Usarla?

Il passaggio al cloud non è più l'unica opzione. Gemma 4 abilita scenari di **Sovereign AI** dove il controllo torna nelle mani dello sviluppatore.

- **Privacy by Design:** I dati sensibili (come le foto dei compiti in GemmaKnow) non lasciano mai la rete locale.
- **Costi API Zero:** Una volta scaricato il modello, l'inferenza è gratuita e illimitata.
- **Latenza Deterministica:** Nessuna coda sul server, nessuna variazione di performance dovuta al traffico internet.
- **Personalizzazione Estrema:** Facilità di fine-tuning e integrazione tramite prompt engineering avanzato (256k contesto).



Cos'è Gemma 4? (Release: Aprile 2026)



Multimodalità Nativamente Integrata

Elabora testo, immagini, audio e video nativamente (specialmente nelle varianti E2B/E4B). Nessun modello separato necessario per la visione pura.



Contesto a 256k Token

Fino a 256.000 token per le varianti medie. Permette di iniettare interi repository di codice o centinaia di pagine PDF in un singolo prompt.




Agentic & Function Calling

Supporto integrato al ruolo di sistema. Il modello traduce comandi naturali in chiamate API o azioni esterne in formato JSON.



Multi-Token Prediction (MTP)

Decodifica speculativa nativa. Include un 'modello bozza' integrato per un'inferenza a bassissima latenza senza perdite di qualità.



Remaining time: 99:30

La Carta d'Identità dei Modelli


Modello	Descrizione Architetture	Use Case Ideale
E2B / E4B (Edge)	Architettura efficiente con Parameter-level Embeddings (PLE).	Deployment su smartphone, Raspberry Pi, o browser via WebGPU. Ottimo per latenza zero.
31B (Dense)	Modello denso. Il ponte tra le prestazioni di livello server e l'esecuzione locale avanzata.	Analisi dati complessa, coding assistance avanzato e generazione testi complessi.
26B A4B (MoE)	Architettura Mixture of Experts. Attiva solo ~4B parametri per token pur avendo una 'cultura' totale da 26B.	Altissima efficienza per task complessi di ragionamento e agenti autonomi. Velocità da modello piccolo, intelligenza da gigante.

Reality Check: Hardware & VRAM

La quantizzazione riduce drasticamente l'impatto sulla memoria.



Insight Tecnico: L'architettura MoE da 26B attiva solo 4B parametri per token per l'inferenza veloce, ma DEVE comunque caricare tutti i 26B in memoria per il routing.




Differenza tra GEMMA 2B e 31B

Le principali differenze tra i modelli Gemma 2B e 31B riguardano il **numero di parametri**, i **dispositivi su cui possono funzionare** e le **tipologie di file che sono in grado di analizzare**:

- Numero di parametri e intelligenza**: La sigla "B" sta per billions (miliardi), il che significa che il modello 2B possiede 2 miliardi di parametri, mentre il modello 31B ne possiede ben 31 miliardi. Poiché i parametri determinano quanto un modello sia in grado di apprendere, ridurre gli errori e fornire risposte precise, il modello 31B risulta essere il più potente e intelligente della famiglia.

- Requisiti hardware**: Avere più parametri rende il modello inevitabilmente più "pesante" da far girare. **Il modello 2B** è progettato per essere leggero e funzionare tranquillamente sui dispositivi mobili come gli smartphone. Al contrario, **il modello 31B** richiede un hardware di fascia medio-alta: non può girare sui telefoni o sui normali laptop, ma necessita di un computer fisso dotato di un'adeguata potenza di calcolo.

- Funzionalità di input supportate**: Le fonti sottolineano di non confondere le dimensioni del modello con la quantità di funzionalità offerte. Sorprendentemente, infatti, il modello più piccolo (2B) è in grado di analizzare sia testo, sia immagini, sia file audio. Il modello più avanzato (31B), pur essendo molto più preciso nelle risposte testuali, può elaborare esclusivamente input di testo e immagini, perdendo quindi la capacità di analizzare l'audio



La finestra di contest e i Token

•**Finestra di contesto:** I modelli della famiglia Gemma 4 sono dotati di una finestra di contesto molto ampia, che va dai 128.000 ai 256.000 token. Nelle impostazioni dei programmi locali è possibile modificare manualmente la "lunghezza del contesto" per adattarla alle proprie esigenze. Viene **sconsigliato** di impostarla al valore massimo per una singola conversazione, poiché risulterebbe un'operazione inutile e finirebbe per rallentare il sistema. Si suggerisce invece di regolarla su valori compresi tra i 4.000 e i 20.000, valutandola in base a quanto tempo impiega il computer a generare la risposta.

•**Token:** I token vengono menzionati esclusivamente in relazione all'output che viene generato dall'intelligenza artificiale. Attraverso le impostazioni relative al sampling (campionamento), l'utente può alterare la "probabilità di generazione dei token": modificare questa probabilità serve, in parole povere, a rendere le risposte del modello più o meno creative.

Il Caso Reale: 'GemmaKnow' AI Tutor

Use Case


Una Web App privata per l'apprendimento delle lingue.


Il Problema

L'utente carica la foto di un compito scritto. L'IA deve leggere il testo (OCR), trovare gli errori grammaticali e spiegarli in italiano.

I Vincoli Architeturali


100% Locale. Nessuna API Cloud esterna. Nessuna fuga di dati. Esecuzione su PC con 16GB di RAM.





HOW TO PLAY ?

Lo Stack Tecnologico (The Polyglot Stack)



Architettura Orchestrata: Usiamo Laravel come direttore d'orchestra per gestire code, storage e persistenza, delegando l'inferenza pesantissima ad Ollama via chiamate HTTP.


Containerizzazione e Topologia Docker



La **persistenza dei volumi** è vitale: senza dichiarare esplicitamente 'mysql_data' e 'ollama_data', i database e i modelli da decine di GB andrebbero persi ad ogni riavvio.

L'Ostacolo: Allucinazioni Visive & RAM Limitata

Aspettativa: Il Modello Tuttofare




Se forzi l'analisi visiva tramite escamotage su hardware limitato, il sistema crolla.

Realtà: Il Limite Fisico

[ERROR 500] model requires more system memory (9.9 GiB) than is available.


Oppure: Allucinazione Visiva ("I leoni mangiano le stelle...")

La Sfida: Su un PC da 16GB, non puoi caricare un enorme modello multimodale in BF16 in un colpo solo. Serve un approccio tattico e diviso in fasi.



2 Pass-Inference

Soluzione Architetture: Double-Pass Inference



Vantaggio Strategico: Efficienza massima e distribuzione del carico. Ogni modello esegue esclusivamente il task per cui è ottimizzato, azzerando le allucinazioni e minimizzando il picco di VRAM contemporaneo.

La Pipeline Neurale GemmaKnow



Input Visivo

L'utente carica l'immagine del compito. I pixel grezzi vengono inviati al server Ollama locale.



Phase 1: LLaVA

Lo strato di visione (OCR) converte i pixel in una stringa di testo grezzo senza interpretazione.



Phase 2: Gemma 4

Il cervello linguistico riceve il testo, analizza la sintassi e genera il feedback da "Professore".





Fase 1: LLaVA - Gli Occhi dell'IA

Digital Vision & OCR


Sviluppato da ricercatori di Wisconsin-Madison e Microsoft, LLaVA è il nostro motore di percezione.

Input: Pixel Image data (Base64)

Prompt: "Agisci come un sistema OCR avanzato..."

Output: Raw String (Testo grezzo trascritto)

Utilizziamo la variante **7B** per garantire precisione nella lettura dei caratteri anche su carta stropicciata o scritte a mano.





Fase 2: **Gemma 4**

Il Tutor Linguistico Esperto

Gemma 4 riceve il testimone da LLaVA. Non è più una questione di "vedere", ma di ****comprendere****. Sfruttando l'architettura MoE da 26B, il modello applica regole sintattiche e semantiche con la precisione di un docente di ruolo.

- ✓ Correzione errori di grammatica
- ✓ Analisi della concordanza tempi verbali
- ✓ Spiegazione didattica in lingua italiana



L'Output: **Feedback** Strutturato



Testo Rilevato (OCR)

Correzione (Gemma 4)

Spiegazione del Professore

"The lion **go** to the forest and..."

"The lion **went** to the forest..."

Hai usato il presente invece del past simple. Trattandosi di una narrazione al passato, è necessario il verbo al passato.

"He **don't** like mouse."

"He **doesn't** like the mouse."

La terza persona singolare (He) richiede l'ausiliare 'does' per la forma negativa, non 'do'.

"A mouse **save** him."

"A mouse **saved** him."

Attenzione alla coerenza temporale: tutto il racconto deve seguire il tempo narrativo del passato.



Sotto il Cofano: Il Codice Laravel (Fase 1 - OCR)

```
1 <?php
2 $imageData = base64_encode(Storage::get($path));
3
4 $ocrResponse = Http::timeout(400)->post('http://ollama:11434/api/generate', [
5     'model' => 'llava:7b',
6     'prompt' => 'Agisci come un sistema OCR. TRASCRIVI esattamente tutto il
7 testo che vedi.',
8     'images' => [$imageData],
9     'stream' => false,
10 ]);
11
```

Insight Operativo: Il client HTTP nativo è indistruttibile. È fondamentale alzare il timeout a 400s: i modelli locali caricati su CPU/GPU consumer richiedono tempo fisiologico per l'allocazione della memoria.

Prompt Engineering: Mitigare il Language Drift

I LLM tendono a tornare all'inglese (lingua di training dominante). Dobbiamo blindare le istruzioni.

Prompt Debole (Rischio Allucinazioni)

Analizza questo testo e correggilo.

Testo: [rawText]

Spiegamelo in italiano.

Risultato: Output misto, formato imprevedibile, l'IA tende a tradurre invece di correggere.

Prompt Blindato (Output Deterministico)

ISTRUZIONI: Rispondi **ESCLUSIVAMENTE** in lingua italiana. Sei un tutor esperto. Analizza il seguente testo estratto da un compito: '[rawText]'.


Segui rigorosamente questo schema:

1. **TESTO RILEVATO:** (inserisci testo)
2. **CORREZIONE:** (inserisci correzione)
3. **SPIEGAZIONE:** (spiega gli errori in italiano)



Parametro API: 'temperature' => 0.3 (Meno creatività poetica, massima precisione analitica).





THE BATTLE



Battle Scars: RAM, WSL2 e Sistemi Operativi

Il Collo di Bottiglia WSL2




Di default, Windows limita Linux al 50% della RAM. Gemma 4 causerà crash o OOM (Out Of Memory).

• • • %UserProfile%\wslconfig

```
[wsl2]
memory=12GB
```

Fix obbligatorio: Assegnare esplicitamente risorse sufficienti all'ambiente virtuale.

Unified Memory (Metal)



L'IA locale è intrinsecamente più fluida grazie alla memoria unificata e al framework Metal. È sufficiente alzare il limite delle risorse direttamente dalla dashboard di Docker Desktop senza script aggiuntivi.





L'IA Enterprise Non È Più Solo In Cloud



Privacy-First

Nessun dato sensibile esce dalla macchina dell'utente. Totale compliance e data-sovereignty.



Zero Costi API

Nessuna tariffazione a consumo per token. Inferenza illimitata sostenuta esclusivamente dal ferro locale.



Controllo Architeturale

Combinando modelli MoE (26B A4B), finestre da 256k e Docker, la logica AI si disaccoppia dal cloud diventando un microservizio interno.

**Scaricate i modelli, configurate il vostro container Ollama, e iniziate a compilare.
Il futuro dell'intelligenza artificiale gira su localhost.**



WHERE TO GET THE BEST OPEN-SOURCE AI MODELS



OLLAMA LIBRARY

READY-TO-USE, OPTIMIZED FOR OLLAMA



Instant
"ollama pull"
command



Optimized
performance



Version Tagging
(e.g., 2b, 7b, vision)



Llama 3



Gemma 2



Mistral



Phi-3



Llava
Vision Model

ollama.com/library



HUGGING FACE

THE GLOBAL HUB FOR AI COMMUNITY & RESEARCH



Millions of models
& datasets



Latest research uploads



Community Discussions



Look for GGUF format
for Ollama compatibility

huggingface.co/models

EXPLORE AND BUILD WITH OPEN AI

Now it's your turn

CLONE THE REPO ***

<https://github.com/gianpierofasulo/gemma4tutor>

follow the instructions in the readme

START THE APP

